

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE SÃO PAULO
CAMPUS CAMPINAS

DANIEL BRAI GONZALES MARCOS
R.A. 3013375

TÍTULO DO TRABALHO AQUI

CAMPINAS
2022

DANIEL BRAI GONZALES MARCOS

TÍTULO DO TRABALHO AQUI

Projeto de Pesquisa apresentado como requisito parcial para aprovação na disciplina “Metodologia de Pesquisa” do curso de Pós-Graduação em Ciência de Dados do Campus Campinas.

CAMPINAS
2022

RESUMO

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Pharetra sit amet aliquam id. Nibh mauris cursus mattis molestie a iaculis at erat pellentesque. Nec tincidunt praesent semper feugiat nibh sed pulvinar proin gravida. Feugiat nibh sed pulvinar proin gravida hendrerit. Turpis massa tincidunt dui ut ornare lectus sit amet est. Enim praesent elementum facilisis leo. Justo nec ultrices dui sapien eget. Fermentum posuere urna nec tincidunt. Placerat in egestas erat imperdiet. Elit at imperdiet dui accumsan sit amet nulla facilisi. Ultricies integer quis auctor elit sed vulputate mi sit. Aliquet eget sit amet tellus.

Palavras-chave: Foo. Bar. XYZ.

SUMÁRIO

1 – INTRODUÇÃO	1
2 – OBJETIVOS	4
2.1 OBJETIVO GERAL	4
2.2 OBJETIVOS ESPECÍFICOS	4
3 – FUNDAMENTAÇÃO TEÓRICA	5
3.1 Processamento de Linguagem Natural (PLN)	5
3.2 Chatbots	7
Referências	8

1 INTRODUÇÃO

O surgimento da Web 2.0 trouxe consigo um novo tipo de aplicação, centrada primariamente ao redor de usuários (ao contrário da Web, a qual é organizada baseada em conteúdo), conhecidas como redes sociais online (do inglês *online social network*, ou apenas OSN), as quais definem e gerenciam relações entre seus usuários. Consideradas uma extensão da própria Web, tais redes tornaram-se um dos mais populares serviços disponíveis na Internet, permitindo uma rica interação entre seus utilizadores, os quais podem publicar uma variedade de tipos de informação, tais qual texto, fotos e vídeos, além de comentá-las, compartilhá-las com outros usuários ou ainda executar diversas outras operações de acordo com o implementado por cada provedor (PALLIS; ZEINALIPOUR-YAZTI; DIKAIKOS, 2011; MISLOVE et al., 2007). Conforme posto por Xia, Yue e Liu (2021), um dos prováveis motivos para a rápida popularização das OSNs seja o fato de tais sistemas servirem como ambiente livre para que indivíduos compartilhem suas opiniões e como canal para que se façam ser ouvidos – e notados, o que é evidenciado através do constante crescimento de usuários das plataformas existentes nos últimos anos, além do surgimento de novos serviços de semelhante natureza (PALLIS; ZEINALIPOUR-YAZTI; DIKAIKOS, 2011).

Há de se observar que, em decorrência da natureza própria apresentada pelas OSNs, tais serviços impactaram, impactam e – provavelmente – continuarão a impactar as relações humanas ainda por algum tempo, sejam estas relações de natureza pessoal ou comercial, assim como a forma que organiza-se, armazena-se e compartilha-se informação e conhecimento (MISLOVE et al., 2007). Quando o discurso *online* é considerado, pode-se encarar as OSNs como um termômetro do que seus usuários pensam ou sentem em relação a um dado tema ou assunto; tal indicativo pode, inclusive, ser estendido aos períodos de eleições – postagens realizadas no intervalo de tempo que antecede ao pleito podem dizer muito sobre o que um usuário – ou grupo de usuários – considera sobre uma ideologia, partido político ou mesmo candidato, a depender do tipo de postagem realizada e da carga de sentimento contida nela (SHEVTSOV et al., 2020). Chaudhry et al. (2021) aponta que uma análise sentimental empregada em postagens realizadas em redes sociais, como Twitter, Instagram ou Facebook (dentre outras), é capaz de demonstrar como a população – ao menos a parte socialmente ativa dentro de tais plataformas – posiciona-se em relação ao pleito e aos candidatos que o disputam, dado que são, atualmente, as principais vias utilizadas para expressar sentimentos, através da discussão de eventos políticos, acontecimentos globais e compartilhamento de notícias.

Ainda que demonstrem um enorme potencial enquanto ferramenta de análise e entendimento de resultados de pleitos eleitorais, não se pode ignorar as limitações observadas quando emprega-se as OSNs para semelhante finalidade. Primeiramente – e talvez a mais evidente – relacione-se à amostragem que as redes sociais digitais oferecem: ao contrário do processo habitual de separação de amostras, tradicionalmente conduzido dentro da disciplina

de estatística, nem toda a população está devidamente representada dentro do universo das redes sociais; esta proposição implica que, como nem todos os votantes fazem uso de tal tipo de comunidade – e que mesmo dentre aqueles que fazem há muitos que restringem o conteúdo compartilhado através das políticas de privacidade oferecidas por cada plataforma, é impossível que tenhamos uma fiel representação da realidade. Um segundo ponto relaciona-se ao conteúdo das publicações, dado que, por conta das limitações encontradas nas ferramentas atualmente disponíveis, a análise invariavelmente sofrerá algum impacto negativo, podendo ser exemplificado pela detecção de sarcasmo – um sentimento amplamente encontrado na dinâmica observada dentro das redes sociais – e que não é percebido facilmente (CHAUDHRY et al., 2021) com o uso das técnicas de Processamento de Linguagem Natural (PNL, ou NLP conforme o original em inglês *Natural Language Processing*). Ainda em relação aos desafios observados no uso e na análise das OSNs, Lovera, Cardinale e Homsí (2021) argumenta que, enquanto um ambiente inteiramente informal, o emprego da língua foge quase que completamente às normas cultas do idioma em questão, qualquer que o seja este, imperando o uso de gírias, abreviações e expressões com significados próprios para nichos específicos, limitando o uso das ferramentas de NLP em sua forma original, sem maiores ajustes ou configurações para a dinâmica das redes. Por fim, há, ainda, o isolamento existente dentro da esfera digital, as chamadas “câmaras de eco”: embora, de fato, a Internet apresente-se como uma poderosa ferramenta de disseminação de ideias e de compartilhamento de informação, promovendo a discussão pública, nota-se o quão fragmentada as OSNs podem se mostrar, atraindo e aglutinando os que, possuindo pensamentos e ideais semelhantes, isolam-se daqueles que enxergam como inimigos (por possuírem opiniões opostas) em comunidades isoladas e segragadas do restante da rede. Em tais comunidades há pouco – quando não nenhum – debate confrontando pensamentos divergentes entre si, enquanto abunda a replicação de ideias e opiniões comuns àqueles que delas participam, as quais circulam repetidamente e as reforçam ainda mais a identidade daquele grupo isolado (TAKIKAWA; NAGAYOSHI, 2017).

Amplamente abordado em âmbito acadêmico (SHEVTSOV et al., 2020; ZAHRAH; NURSE; GOLDSMITH, 2022; CHAUDHRY et al., 2021; TAKIKAWA; NAGAYOSHI, 2017; XIA; YUE; LIU, 2021), a utilização das redes sociais digitais como ferramenta de análise e predição para resultados de eleições ainda posiciona-se como estratégia válida a medida que novas técnicas para processamento de texto e afins são desenvolvidas. Ademais, a aplicação de técnicas de explicabilidade podem dotar tais análises de maior robustez, ao fornecer indícios de como os modelos aplicados funcionam internamente; com este entendimento, é possível refinar tais modelos, evitando vieses e diminuindo ruídos, prevenindo e retificando conclusões incorretas ao depurar o modelo aplicado. É neste contexto que o LIME (*Local Interpretable Model-agnostic Explanations*) é inserido, explicando como um dado ponto classificado de uma forma e não de outra, sendo alocado a numa classe específica, permitindo o referido entendimento do modelo aplicado, independente de qual técnica tenha sido aplicado para o trabalho de predição e/ou classificação (CONFALONIERI et al., 2021; LOVERA; CARDINALE; HOMSI, 2021), sendo a

presente proposta centrada em aliar-se um modelo de classificação ao LIME, posicionando-o ao final do processo de análise de sentimentos da rede social Twitter. A escolha do Twitter enquanto OSN para estudo deu-se pela importância que a rede assumiu enquanto ferramenta de difusão de informação e de mobilização popular para diversos movimentos políticos de impacto global, como a Primavera Árabe (2010), o OWS (*Occupy Wall Street*, 2011), os protestos no Parque Gezi (2013) ([TAKIKAWA; NAGAYOSHI, 2017](#)) ou mesmo o movimento Passe Livre (2013), ao longo da última década, além de a própria rede posicionar-se como um palco para o debate público, como um lugar livre para esta finalidade.

2 OBJETIVOS

2.1 OBJETIVO GERAL

Analisar o engajamento político dos brasileiros nas redes sociais em relação aos possíveis presidenciáveis para o pleito de 2022.

2.2 OBJETIVOS ESPECÍFICOS

- Coletar os dados e metadados de perfis de usuários do Twitter relacionados aos possíveis presidenciáveis;
- Consolidar os registros obtidos em uma base de dados modelada usando o princípio de seguidores recíprocos;
- Identificar os termos associados a cada grupo representado pelos pré-candidatos;
- Processar a base de dados construída com o uso de técnicas de NLP e modelos de classificação;
- Aplicar o LIME em cima do modelo de classificação empregado;
- Construir um panorama da distribuição dos usuários do Twitter em relação ao seu posicionamento político considerando possíveis candidatos à presidência e os termos identificadores elencados.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 Processamento de Linguagem Natural (PLN)

O Processamento de Linguagem Natural (PLN, ou NLP - do inglês *Natural Language Processing*) pode ser definido, conforme proposto por [Cambria e White \(2014\)](#), como “um conjunto de técnicas computacionais para representação e análise automática da linguagem humana”. Neste contexto, sendo a linguagem a principal ferramenta pela qual seres humanos estabelecem seu padrão comportamental para a vida em sociedade e, conseqüentemente, a forma mais natural de interação da qual rotineiramente lançam mão em seu cotidiano ([ALLEN, 1988](#)), é compreensível que a construção de soluções computacionais que explorem tal interface – como interpretá-la, extrair informações e mesmo compreendê-la – tenha permeado tantos trabalhos e pesquisas ao longo das décadas, desde a primeira proposição abordando o tema, ainda na década de 1950 ([CAMBRIA; WHITE, 2014](#)). Uma das grandes motivações para explorar esta disciplina advém do fato de que o conhecimento humano está registrado majoritariamente de forma linguística (mídias audiovisuais como um todo - livros, vídeos, conteúdos de áudio e afins), logo modelos computacionais que consigam transpor a barreira da linguagem humana podem acessar – e entender – a toda esta informação, processando-a e tornando o processo de consumo a qualquer um que o deseje (ou necessite) fazê-lo mais simples e menos moroso, implicando em sistemas mais flexíveis e inteligentes que aqueles atualmente disponíveis ([ALLEN, 1988](#)).

Dada a complexidade inerente à linguagem humana, o Processamento de Linguagem Natural exige uma capacidade simbólica de alto nível por parte da máquina que o está operando, a qual é naturalmente observada nos seres humanos – revelando-se, de certa forma, uma capacidade trivial possuída pelo homem, dado serem estes os responsáveis pelo desenvolvimento da língua enquanto ferramenta comunicativa; isso decorre do fato de que cada palavra carrega em si uma intrincada relação semântica, permeada por diversos conceitos, envolvendo episódios relevantes e mesmo experiências particulares para os envolvidos no processo de comunicação. ([CAMBRIA; WHITE, 2014](#)). Para habilitar uma aplicação baseada em NLP é necessário dotá-la de um considerável conhecimento da estrutura do idioma em si na qual aquele sistema foi construído (isto é, inglês, português, espanhol, mandarim etc), o que envolve conhecer os vocábulos pertencentes àquele idioma, como as palavras se interconectam para gerar sentenças e como tais vocábulos criam sentido, divergindo de seu significado literal, a depender do contexto no qual encontram-se inseridos (denotação e conotação); por fim, é preciso que a aplicação também seja apresentado ao campo lexical encerrado pelo domínio de negócio que se busca abordar ([ALLEN, 1988](#)).

Dado o exposto, o desenvolvimento da disciplina de NLP baseia-se, fundamentalmente, em três pilares - **Sintaxe**, o qual especifica como os símbolos significativos para a língua são




Figura 1 – Figura 1: As Áreas do Conhecimento Linguístico (ALLEN, 1988; CAMBRIA; WHITE, 2014)

agrupados logicamente; **Semântica**, responsável por definir como as expressões são formadas e qual o seu suposto significado; e **Contexto**, que encerra os mecanismos que possibilitam estabelecer correlações entre diferentes semânticas e permite a desambiguação da informação consumida. Destaca-se o fato de que os trabalhos iniciais na área, desenvolvidos ainda na década de 1950, foram construídos abordando fundamentalmente os mecanismos para o processamento da estrutura formal da língua em si (Sintaxe), justificando-se por ser (1) uma etapa necessária ao avanço para abordar os demais pilares (Semântica e Contexto) e (2) por possuir uma aplicação mais direta e imediata nas técnicas de aprendizagem de máquina (CAMBRIA; WHITE, 2014).

Para Allen (1988), além da visão sistêmica demonstrada anteriormente, há ainda um agrupamento mais específico das áreas de conhecimento relevantes ao entendimento da linguagem; para o autor, para aplicações centradas numa interação escrita, pode-se elencar como relevantes ao sistema os seguintes conhecimentos: (1) **Conhecimento Morfológico** (conhecer como as palavras são construídas no idioma ao qual o sistema busca atender - a exemplo, as palavras ferro, ferrugem e ferradura derivam todas do mesmo radical, ferr); (2) **Conhecimento Sintático** (como as palavras podem ser agrupadas, e qual o papel de cada vocábulo na estrutura construída); (3) **Conhecimento Semântico** (implica no conhecimento do significado das palavras e como estes podem ser empregadas para a construção de sentenças com significados que possuam sentido e significado, independente do contexto no qual foram empregados); (4) **Conhecimento Pragmático** (como sentenças empregadas em contextos diferentes podem assumir significados igualmente diferentes); (5) **Conhecimento do Diálogo** (como sentenças afetam umas às outras, impactando na interpretação do discurso conduzido - principalmente em relação ao emprego de pronomes e ao fluxo do diálogo ao longo do tempo);

(6) **Conhecimento de Domínio** (compete ao entendimento do contexto no qual os usuários daquele domínio empregam cada vocábulo). Para aplicações cujo meio de interação com o usuário seja a voz, há a necessidade de um campo de conhecimento adicional, o **Conhecimento Fonético e Fonológico** (que se relaciona a forma como cada vocábulo relaciona-se com os sons que os representam). O relacionamento entre as áreas apresentadas pode ser melhor observado na representação vista na figura 1.

3.2 Chatbots

Referências

- ALLEN, J. **Natural language understanding**. [S.l.]: Benjamin-Cummings Publishing Co., Inc., 1988. Citado 2 vezes nas páginas 5 e 6.
- CAMBRIA, E.; WHITE, B. Jumping nlp curves: A review of natural language processing research. **IEEE Computational intelligence magazine**, IEEE, v. 9, n. 2, p. 48–57, 2014. Citado 2 vezes nas páginas 5 e 6.
- CHAUDHRY, H. N. et al. Sentiment analysis of before and after elections: Twitter data of us election 2020. **Electronics**, Multidisciplinary Digital Publishing Institute, v. 10, n. 17, p. 2082, 2021. Citado 2 vezes nas páginas 1 e 2.
- CONFALONIERI, R. et al. A historical perspective of explainable artificial intelligence. **Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery**, Wiley Online Library, v. 11, n. 1, p. e1391, 2021. Citado na página 2.
- LOVERA, F. A.; CARDINALE, Y. C.; HOMSI, M. N. Sentiment analysis in twitter based on knowledge graph and deep learning classification. **Electronics**, Multidisciplinary Digital Publishing Institute, v. 10, n. 22, p. 2739, 2021. Citado na página 2.
- MISLOVE, A. et al. Measurement and analysis of online social networks. In: **Proceedings of the 7th ACM SIGCOMM conference on Internet measurement**. [S.l.: s.n.], 2007. p. 29–42. Citado na página 1.
- PALLIS, G.; ZEINALIPOUR-YAZTI, D.; DIKAIKOS, M. D. Online social networks: status and trends. **New directions in web data management 1**, Springer, p. 213–234, 2011. Citado na página 1.
- SHEVTSOV, A. et al. Analysis of twitter and youtube during uselections 2020. **arXiv preprint arXiv:2010.08183**, 2020. Citado 2 vezes nas páginas 1 e 2.
- TAKIKAWA, H.; NAGAYOSHI, K. Political polarization in social media: Analysis of the “twitter political field” in japan. In: IEEE. **2017 IEEE international conference on big data (big data)**. [S.l.], 2017. p. 3143–3150. Citado 2 vezes nas páginas 2 e 3.
- XIA, E.; YUE, H.; LIU, H. Tweet sentiment analysis of the 2020 us presidential election. In: **Companion Proceedings of the Web Conference 2021**. [S.l.: s.n.], 2021. p. 367–371. Citado 2 vezes nas páginas 1 e 2.
- ZAHRAH, F.; NURSE, J. R.; GOLDSMITH, M. A comparison of online hate on reddit and 4chan: A case study of the 2020 us election. **arXiv preprint arXiv:2202.01302**, 2022. Citado na página 2.